

BÁO CÁO KỸ THUẬT

AI CHALLENGE TP.HCM 2026

Đội Reply404 – Bảng A – Mã đội 586

Tóm tắt. Reply 404 xây dựng một hệ thống truy hồi video tương tác cho ba dạng nhiệm vụ KIS, Q&A và TRAKE. Kênh thị giác có năm provider độc lập: SigLIP2, Qwen3-VL Embedding, MetaCLIP2, PE-Core và BEiT-3. Hệ thống kết hợp visual retrieval, OCR, ASR, hợp nhất kết quả muộn, ràng buộc chuỗi thời gian và giao diện kiểm duyệt trước khi xuất đáp án.

Kiến trúc và quy trình xử lý

Hệ thống hoạt động theo hai pha. Trong **offline data preprocessing**, video dataset được TransNetV2 phân tích để phát hiện *shot boundary*; từ mỗi shot, hệ thống trích các keyframe đại diện và gán định danh chuẩn

`frame_uid = video_id:source_frame_idx.`

Các visual embedding, văn bản OCR và hai bản transcript ASR được tính trước rồi lưu trong các index chuyên biệt. Trong **online query processing**, truy vấn được phân thành một hoặc nhiều stage; từng retrieval channel trả ứng viên độc lập, sau đó hệ thống chuẩn hóa, fusion, áp dụng temporal constraints, nhóm theo video và hiển thị cho người vận hành [12].




Figure 1: Luồng tổng thể: 5 visual provider/index độc lập, OCR/ASR, late fusion, DANTE và CSV export.

Các kênh truy hồi

Thị giác. Hệ thống cung cấp 5 provider/index độc lập: **SigLIP2** (google/siglip2-so400m-patch14-384, 1.152 chiều), **Qwen3-VL** (Qwen/Qwen3-VL-Embedding-2B, 2.048), **MetaCLIP2** (facebook/metaclip-2-worldwide-huge-378, 1.024), **PE-Core** (facebook/PE-Core-G14-448, 1.280) và **BEiT-3** (BEiT3-large-patch16-384-coco-retrieval, 1.024) [1, 3, 2, 4, 5]. Mỗi index chứa 146.121 keyframe float32 đã chuẩn hóa L_2 và dùng **FAISS IndexFlatIP** [6]; các embedding space không bị nối thành một vector. SigLIP2 là mặc định, provider còn lại được chọn theo truy vấn; runtime giữ tối đa hai visual provider resident cùng lúc với gate 23,3 GB process RSS.

OCR. Pipeline gồm DeepSolo (ResNet-50, dữ liệu DSText) để phát hiện vùng chữ và PARSeq được tinh chỉnh cho tiếng Việt để nhận dạng [7, 8]. Văn bản được chuẩn hóa nhưng vẫn giữ liên kết về keyframe gốc, hỗ trợ truy vấn cụm từ, dấu tiếng Việt và duyệt các khung lân cận.

ASR. Offline, mỗi audio track được phiên âm độc lập bằng vinai/PhoWhisper-large và Whisper-large-v3 [9, 11]; transcript được lưu theo segment cùng timestamp. Runtime giữ hai field tìm kiếm folded phowhisper_folded và whisper_v3_folded, cùng hai field raw phowhisper_raw và whisper_v3_raw để hiển thị. UI hỗ trợ tìm từng model hoặc **RRF** trên hai field; segment khớp được ánh xạ sang keyframe gần nhất theo timeline và không chạy lại ASR khi tìm kiếm.

Truy vấn và tương tác

Mỗi stage nhận truy vấn **Text**, **Image**, **OCR** hoặc **ASR**. Người dùng có thể thêm/bớt stage, chọn mô hình thị giác sẵn có, giới hạn video, số kết quả và khoảng cách thời gian; sau đó chuyển giữa chế độ tất cả hit và nhóm theo video. Cách tổ chức này phù hợp cả truy vấn một cảnh và truy vấn chuỗi nhiều sự kiện.

Xếp hạng, lọc và chiến lược thi đấu

Late fusion

Điểm của mỗi channel chỉ có ý nghĩa trong score space riêng. Visual provider được chuẩn hóa độc lập rồi dùng **harmonic mean** khi chạy nhiều provider; các kênh text/ASR giữ thứ hạng riêng, trong đó hai transcript ASR dùng **RRF** trên hai field folded. Kênh không bật hoặc không sẵn sàng được bỏ qua thay vì gán điểm 0; mọi evidence vẫn giữ `frame_uid` để DANTE, Inspector và CSV dùng chung [10].

Temporal constraints với DANTE


Với TRAKE, hệ thống tìm một bundle hoàn chỉnh thỏa các điều kiện: mỗi stage chọn đúng một frame, cùng video, khác định danh, timestamp tăng nghiêm ngặt và khoảng cách kề nhau không vượt ngưỡng. **Exact solver** được dùng làm chuẩn; **optimized solver** dùng timestamp sweep và Fenwick prefix-maximum cho linear constraint case, còn cấu hình phức tạp fallback về exact solver. Kết quả được ranking theo bundle score thay vì score đơn lẻ của từng frame.

Table 1: Vai trò của các thành phần trong cấu hình thi đấu


Thành phần	Vai trò	Giá trị vận hành
5 visual provider	SigLIP2, Qwen3-VL, MetaCLIP2, PE-Core, BEiT-3	Chọn embedding space phù hợp truy vấn; mỗi model có FAISS index riêng
OCR / Dual ASR	Truy hồi chữ trên màn hình và hai transcript	Tăng recall cho tên riêng, khẩu hiệu và lời nói
DANTE	Ghép stage theo video và thời gian	Loại chuỗi thiếu, đảo thứ tự hoặc vượt khoảng cách
Inspector + Queue	Kiểm tra nguồn và chuẩn bị nộp	Giảm nhiễu video/frame trước khi xuất CSV

Giao diện hệ thống

Giao diện được tối ưu cho thao tác trong thời gian thi đấu. Cột trái là query composer nhiều stage; thanh trên điều khiển mô hình, chế độ nhóm, bộ lọc video, top-*k* và gap. Khu vực giữa hiển thị keyframe chính cùng các khung lân cận; cột phải là review queue và công cụ xuất/review CSV.



(a) Query Composer: (1) 5 lựa chọn visual provider; (2) tab modality; (3) encoder theo stage; (4) chuỗi prompt có thứ tự; (5) thêm/bớt stage.



(b) TRAKE Gallery: (1) All Hits/Grouped; (2) bộ lọc stage-video-Top-k-gap; (3) mã bundle đang xem; (4) dải primary/nearby keyframes; (5) ô kết quả gắn nhãn stage.

Figure 2: Luồng nhập truy vấn và duyệt kết quả TRAKE.

Kiểm chứng kết quả và chuẩn bị nộp

Khi chọn một ứng viên, **Inspector** mở video tại đúng timestamp, hiển thị video_id, source_frame_idx, đường dẫn nguồn, thời lượng và dải khung lân cận. Đây là bước quan trọng để phát hiện keyframe gần đúng nhưng sai thời điểm. Người dùng có thể thêm khung đã xác nhận vào **Review Queue**, kiểm tra lại thứ tự stage, rồi xuất CSV theo định dạng của hệ thống đánh giá.






Figure 3: Inspector: (1) định danh nguồn và score; (2) timestamp phát video; (3) công cụ đánh dấu biên thời gian; (4) mốc stage trên timeline; (5) kiểu truy vấn KIS/QA/TRAKE.



(a) OCR Search: (1) chế độ OCR; (2) thêm cụm từ; (3) chip cụm từ đã xếp; (4) tiêu đề evidence primary/nearby; (5) thống kê hit-video-độ trễ.



(b) Review Queue: (1) phiên riêng; (2) kết quả đã chọn; (3) định danh video/stage/frame; (4) xóa item; (5) xuất CSV.

Figure 4: Evidence chuyên biệt và bước lựa chọn đáp án.

Điểm khác biệt của giải pháp

- **Định danh xuyên suốt:** cùng một frame_uid được dùng từ chỉ mục, API, gallery, inspector đến CSV, hạn chế sai lệch giữa vị trí keyframe và số frame nguồn.
- **Multi-provider visual retrieval:** năm model truy hồi trên cùng danh mục 146.121 keyframe bằng năm FAISS index độc lập; operator chọn provider theo đặc điểm truy vấn.
- **Human-in-the-loop:** hệ thống ưu tiên tốc độ khám phá nhưng luôn cho phép xem video, duyệt lân cận và xác nhận thủ công trước khi nộp.
- **Chỉ mục tách biệt, hợp nhất nhất quán:** mỗi mô hình giữ FAISS index và phân phối điểm riêng; frame_uid là khóa chung để fusion, DANTE và xuất kết quả.

Phân tích các truy vấn đại diện

Tình huống 1: query-p2-8-trake – chuỗi bốn loại trái cây

Đặc điểm. Truy vấn yêu cầu lần lượt xuất hiện sầu riêng, măng cụt, bưởi và dâu bòn bon. Thách thức nằm ở sự giống nhau về bối cảnh vườn/chợ, cách gọi địa phương của “dâu bòn bon” và yêu cầu đúng thứ tự thời gian.

Cách xử lý. Đội tạo bốn stage text, dùng SigLIP2 để lấy ứng viên từng cảnh, chuyển sang Grouped để tìm video có đủ stage, rồi để DANTE kiểm tra thứ tự và khoảng cách. Các thumbnail lân cận và Inspector được dùng để loại các chuỗi có cảnh lặp hoặc sai loại quả.

Kết quả. Video phù hợp là L27_V011; chuỗi anchor đã chọn:

L27_V011,3814,3877,4028,4108

Hệ thống làm tốt việc thu hẹp từ nhiều hit rồi rọc thành một bundle hợp lệ. Hạn chế chính là từ khóa dân gian và cảnh quay cận có thể khiến mô hình thị giác nhầm giữa các loại quả; bài học là dùng mô tả đồng nghĩa và luôn kiểm tra toàn bộ chuỗi trong cùng video.

Tình huống 2: query-p2-21-trake – quy trình xếp và vận chuyển thùng hàng

Đặc điểm. Truy vấn mô tả bốn hành động gần nhau: dán kín thùng carton; các thùng mì/gói bánh được xếp; một người đàn ông nâng thùng mì; cận cảnh thùng trên xe tải. Các cảnh có nền kho hàng tương tự và dễ khớp đúng vật thể nhưng sai hành động.

Cách xử lý. Mỗi hành động trở thành một stage riêng. Tìm kiếm ngữ nghĩa tạo shortlist, DANTE ép thứ tự, và người vận hành xem timeline để xác nhận chuyển tiếp từ đóng gói sang bốc xếp và vận chuyển.

Kết quả. Video đúng đầu là L30_V031; chuỗi nẹp:

L30_V031,2106,2143,2179,2235

Ràng buộc thời gian loại được nhiều hit kho hàng không liên quan. Hạn chế là keyframe có thể nằm trước/sau đỉnh hành động; Inspector và nearby frames vẫn cần thiết để chọn frame đại diện chính xác.

Bài học

Nhìn chung, hệ thống mạnh ở truy hồi đa kênh, ràng buộc chuỗi và kiểm chứng tương tác. Hạn chế còn lại gồm chi phí tài nguyên của mô hình thị giác lớn, sai số OCR trên chữ nhỏ/nghe, sai số ASR trong âm thanh nhiễu và sự phụ thuộc vào keyframe đã trích. Hướng cải tiến là hiệu chỉnh fusion bằng dữ liệu phát triển, reranking đa phương thức và đề xuất truy vấn tự động theo các hit đã xác nhận.

References

- [1] M. Tschanen et al., “SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features,” arXiv:2502.14786, 2025.
- [2] Y.-S. Chuang et al., “Meta CLIP 2: A Worldwide Scaling Recipe,” arXiv:2507.22062, 2025.
- [3] Qwen Team, “Qwen3-VL-Embedding-2B model card,” <https://huggingface.co/Qwen/Qwen3-VL-Embedding-2B>.
- [4] Meta, “PE-Core-G14-448 model card,” <https://huggingface.co/facebook/PE-Core-G14-448>.
- [5] Microsoft, “BEiT3 large COCO retrieval checkpoint,” model documentation.
- [6] M. Douze et al., “The Faiss Library,” arXiv:2401.08281, 2024.
- [7] M. Ye et al., “DeepSolo: Let Transformer Decoder with Explicit Points Solo for Text Spotting,” CVPR, 2023.
- [8] D. Bautista and R. Atienza, “Scene Text Recognition with Permuted Autoregressive Sequence Models,” ECCV, 2022.
- [9] T.-T. Le, L. T. Nguyen, and D. Q. Nguyen, “PhoWhisper: Automatic Speech Recognition for Vietnamese,” ICLR Tiny Papers, 2024.
- [10] G. V. Cormack, C. L. A. Clarke, and S. Buettcher, “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods,” SIGIR, 2009.
- [11] A. Radford et al., “Robust Speech Recognition via Large-Scale Weak Supervision,” ICML, 2023.
- [12] T. Souček and J. Lokoč, “TransNet V2: An Effective Deep Network Architecture for Fast Shot Transition Detection,” arXiv:2008.04838, 2020.